

КОРРЕЛЯЦИОННЫЙ И РЕГРЕССИОННЫЙ АНАЛИЗ


Модуль 3. Элементы математической статистики

Лекция 8. Понятие о регрессионном и корреляционном анализе

1. Понятие о регрессионном и корреляционном анализе.
Линейная регрессия.
2. Вывод уравнения линейной регрессии методом наименьших квадратов (МНК).
3. Коэффициент корреляции Пирсона.
4. Коэффициенты ранговой корреляции (Спирмена, Кендалла)

ФАЙЛЫ:

- МС_Карасев В.А., Лёвшина Г.Д. МИСИС. Статистика 2770
- МС_Боголюбов_ПР.ЗАН
- Л.8.2_ПРИМЕРЫ ЛИНЕЙНОЙ РЕГРЕССИИ
- Л.8.1_Коэффициент корреляции Спирмена, Кендалла



Корреляционно-регрессионный анализ

Корреляционный анализ – это статистический метод исследования связей случайных величин

$$Y \text{ и } X_j \quad (j = \overline{1, k}).$$

Задачи корреляционного анализа:

- существует ли зависимость между СВ,
- определение коэффициента корреляции для СВ,
- насколько сильно взаимосвязаны СВ

Инструмент исследований –
коэффициент корреляции




- **Регрессионный анализ** – это статистический метод исследования вида зависимости случайной величины Y от величин X_j ($j = \overline{1, k}$).

Задачи регрессионного анализа:

- установление вида зависимости между СВ,
- определение параметров выбранной зависимости,
- анализ **адекватности** модели и **значимости коэффициентов**, т.е. соответствие эмпирическим данным,
- определение неизвестных значений (**прогноз**)

Инструмент исследований – регрессионная модель (линейная, квадратичная, полиномиальная, экспоненциальная и т.д.)



Если каждому значению X соответствует свое значение $M(Y|X)$, то зависимость

$$M(Y | X) = f(X)$$

называется *функцией регрессии Y на X* .

При рассмотрении зависимости

- двух переменных говорят о *парной регрессии*:

$$M(Y | X) = f(X)$$

- нескольких переменных говорят о *множественной регрессии*

$$M(Y | X_1, X_2, \dots, X_k) = f(X_1, X_2, \dots, X_k).$$



УРАВНЕНИЯ ЛИНЕЙНОЙ РЕГРЕССИИ

Ковариация или **корреляционный момент** случайных величин X и Y - это математическое ожидание произведения отклонений случайных величин X и Y от их математических ожиданий: $\text{Cov}(X, Y) = K_{xy} = M((X - m_x) \cdot (Y - m_y))$.

Ковариацию можно записать в виде: $\text{Cov}(X, Y) = K_{xy} = M(X \cdot Y) - m_x \cdot m_y$
 m_x, m_y - математическое ожидание X и Y .

Коэффициент корреляции (Пирсона) $r_{xy} = \frac{K_{xy}}{\sigma_x \cdot \sigma_y}$,

σ_x, σ_y - средние квадратические отклонения X и Y ;

m_x, m_y - математические ожидания X и Y .

- **Линейная регрессия Y на X :** $y - m_y = r_{xy} \frac{\sigma_y}{\sigma_x} (x - m_x)$
- **Линейная регрессия X на Y :** $x - m_x = r_{xy} \frac{\sigma_x}{\sigma_y} (y - m_y)$

Эти прямые пересекаются в точке (m_x, m_y) - в центре распределения

ВЫБОРОЧНЫЕ ХАРАКТЕРИСТИКИ ДВУМЕРНОЙ ВЫБОРКИ

Пусть (x_i, y_i) , $i = 1, 2, \dots, n$, — двумерная выборка объема n из значений случайного двумерного вектора (ξ, η) . Изображение элементов выборки в виде точек на координатной плоскости называется *диаграммой рассеяния*.

Точечными оценками математических ожиданий $\mathbf{M}\xi$ и $\mathbf{M}\eta$ служат выборочные средние

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \text{ и } \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i,$$

дисперсий $\mathbf{D}\xi$ и $\mathbf{D}\eta$ — несмешенные оценки дисперсий

$$s^2(\xi) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n-1} \left(\sum_{i=1}^n x_i^2 - n\bar{x}^2 \right) \text{ и}$$

$$s^2(\eta) = \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2 = \frac{1}{n-1} \left(\sum_{i=1}^n y_i^2 - n\bar{y}^2 \right),$$

ковариации $\text{cov}(\xi, \eta)$ — *несмешенная выборочная ковариация*

$$k(\xi, \eta) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \frac{1}{n-1} \left(\sum_{i=1}^n x_i y_i - n\bar{x}\bar{y} \right),$$

коэффициента корреляции $r(\xi, \eta)$ — *выборочный коэффициент корреляции*

$$r(\xi, \eta) = \frac{k(\xi, \eta)}{s(\xi)s(\eta)}.$$



УРАВНЕНИЯ ВЫБОРОЧНОЙ ЛИНЕЙНОЙ РЕГРЕССИИ

s_x^2, s_y^2 - выборочные исправленные оценки дисперсий X, Y ;
 \bar{x}, \bar{y} - выборочные средние оценки математических
ожиданий X, Y .

- Выборочная линейная регрессия Y на X :


$$y - \bar{y} = r_{xy(\epsilon)} \frac{s_y}{s_x} (x - \bar{x})$$

- Выборочная линейная регрессия X на Y :


$$x - \bar{x} = r_{xy(\epsilon)} \frac{s_x}{s_y} (y - \bar{y})$$

Спецификация уравнения регрессии.

В случае парной регрессии – графический анализ реальных статистических данных (поле рассеивания).




Линейная зависимость $\hat{Y} = \beta_0 + \beta_1 X$.




Квадратичная зависимость:

$$\hat{Y} = \beta_0 + \beta_1 X + \beta_2 X^2$$




Степенная зависимость

$$\hat{Y} = \beta_0 X^{\beta_1}$$




Показательная зависимость


$$\hat{Y} = \beta_0 e^{\beta_1 X}$$



Гиперболическая зависимость $\hat{Y} = \beta_0 + \frac{\beta_1}{X}$




X и Y независимы



Выход уравнения линейной выборочной регрессии (МНК).


Выборка: (x_i, y_i) – результат i -го наблюдения, $i=1, \dots, n$.




Выборочная линия регрессии

$$\hat{y} = b_0 + b_1 x,$$

где b_0 и b_1 – неизвестные параметры, которые подбираются по методу наименьших квадратов.



$$Q = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - b_0 - b_1 x_i)^2 \rightarrow \min$$



Найдем частные производные Q и приравняем их к нулю:

$$\begin{cases} \frac{\partial Q}{\partial b_0} = -2 \sum_{i=1}^n (y_i - b_0 - b_1 x_i) = 0; \\ \frac{\partial Q}{\partial b_1} = -2 \sum_{i=1}^n (y_i - b_0 - b_1 x_i) x_i = 0. \end{cases}$$

Получим **систему линейных уравнений**:

$$\begin{cases} nb_0 + b_1 \sum x_i = \sum y_i \\ b_0 \sum x_i + b_1 \sum x_i^2 = \sum x_i y_i \end{cases} \quad \text{или} \quad \begin{cases} b_0 + b_1 \bar{x} = \bar{y} \\ b_0 \bar{x} + b_1 \bar{x}^2 = \bar{xy} \end{cases}$$

Решая систему, получаем:


$$b_0 = \bar{y} - b_1 \bar{x},$$

$$b_1 = \frac{\bar{xy} - \bar{x} \cdot \bar{y}}{\bar{x}^2 - (\bar{x})^2} = \frac{K_{xy(\epsilon)}}{S_x^2} = r_{xy(\epsilon)} \frac{S_y}{S_x},$$

$$\bar{x} = \frac{\sum x_i}{n}; \quad \bar{x}^2 = \frac{\sum x_i^2}{n};$$

$$\bar{y} = \frac{\sum y_i}{n}; \quad \bar{xy} = \frac{\sum x_i y_i}{n}.$$

$$\hat{y} = b_0 + b_1 x = \bar{y} + r_{xy(\epsilon)} \frac{S_y}{S_x} (x - \bar{x})$$



АДЕКВАТНОСТЬ ЛИНЕЙНОЙ МОДЕЛИ РЕГРЕССИИ



Коэффициент детерминации – наиболее эффективная оценка адекватности линейной регрессионной модели:

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2} = r_{xy(\varepsilon)}^2,$$
$$\hat{y}_i = b_0 + b_1 x_i$$

y_i – выборочные значения,

\bar{y} – выборочное среднее,

\hat{y}_i – теоретические значения,

Свойства коэффициента детерминации.

1. $0 \leq R^2 \leq 1$.
2. $R^2 = 0$ – Y и X независимы.
3. $R^2 = 1$ – функциональная линейная зависимость между Y и X .
4. $0 < R^2 < 1$ – чем ближе R^2 к 1, тем точнее подгонка кривой к опытным данным.

R^2 применяется для проверки значимости уравнения регрессии. Гипотеза H_0 : модель неадекватна; гипотеза H_1 : модель адекватна.


$$H_0: R^2 = 0; \quad H_1: R^2 \neq 0$$

.

Рассчитывают статистику Фишера:

$$F_{\text{набл}} = \frac{R^2}{1 - R^2} (n - 2).$$

Если $F_{\text{набл}} > F_{kp} = F_{1-a, 1, n-2}$ то гипотеза отвергается и уравнение считается значимым.



ИНТЕРВАЛЬНОЕ ОЦЕНИВАНИЕ КОЭФФИЦИЕНТОВ ЛИНЕЙНОЙ РЕГРЕССИИ

Доверительным интервалом называется интервал, относительно которого можно с заранее выбранной вероятностью утверждать, что он содержит значения прогнозируемого показателя.

Интервальная оценка для параметра β_0 :

$$\beta_0 \in \left(b_0 \pm t_{\alpha, n-2} \cdot \hat{S}_{b_0} \right), \text{ где}$$

$t_{kp}(\alpha; v=n-2)$ определяется из *таблицы распределения Стьюдента для двусторонней критической области для уровня значимости α* и числа степеней свободы $v=n-2$.

Аналогично определяется интервальная оценка для коэффициента β_1 :

$$\beta_1 \in \left(b_1 \pm t_{\alpha, n-2} \cdot \hat{S}_{b_1} \right)$$

$$S = \frac{1}{n-2} \sum (y_i - \hat{y}_i)^2$$

$$\hat{S}_{b_0} = \sqrt{\frac{\hat{S}^2 \sum x_i^2}{n \sum_{i=1}^n x_i^2 - (\sum x_i)^2}} = S \frac{\sqrt{\sum x_i^2}}{n \cdot S_x}$$

$$\hat{S}_{b_1} = \sqrt{\frac{\hat{S}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}} = S \frac{\sqrt{n}}{n \cdot S_x}.$$