

ПРАКТИЧЕСКОЕ ЗАНЯТИЕ 12.

РЕГРЕССИОННЫЙ АНАЛИЗ. ПОСТРОЕНИЕ ЛИНЕЙНОЙ И КВАДРАТИЧНОЙ РЕГРЕССИОННЫХ МОДЕЛЕЙ

1. Задача регрессии для линейной функции.

Рассмотрим случай, когда уравнение регрессии (1.61) является линейной функцией

$$y = \beta_1 + \beta_2 x, \quad (1.69)$$

т.е. базисные функции $\varphi_1(x) = 1$, $\varphi_2(x) = x$. В этом случае система (1.63) имеет вид

$$\begin{cases} \beta_1 n + \beta_2 \sum_{i=1}^n x_i = \sum_{i=1}^n Y_i \\ \beta_1 \sum_{i=1}^n x_i + \beta_2 \sum_{i=1}^n x_i^2 = \sum_{i=1}^n Y_i x_i \end{cases} \quad (1.70)$$

Расчет упростится, если ввести замену $X = \frac{x - \bar{x}}{h}$ и рассматривать уравнение

$$y = B_1 + B_2 X = B_1 + B_2 \frac{x - \bar{x}}{h}, \quad (1.71)$$

где $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ – среднее арифметическое аргументов x , h выбирается из условия, чтобы

значения X были целыми не имеющими общего множителя. Уравнение (1.71) будем называть уравнением с *кодированным переменным*, в отличие от уравнения (1.69) с

реальным переменным. В этом случае $\sum_{i=1}^n X_i = 0$ и система (1.70) будет иметь вид

$$\begin{cases} B_1 n = \sum_{i=1}^n Y_i \\ B_2 \sum_{i=1}^n x_i^2 = \sum_{i=1}^n Y_i x_i \end{cases}$$

Откуда имеем формулы для оценок коэффициентов регрессии уравнения с кодированным переменным:

$$\tilde{B}_1 = \frac{\sum_{i=1}^n Y_i}{n}, \quad \tilde{B}_2 = \frac{\sum_{i=1}^n Y_i X_i}{\sum_{i=1}^n X_i^2}. \quad (1.72)$$

Для контроля расчетов удобно воспользоваться свойством отклонений $\Delta Y_i = Y_i - \tilde{Y}(x_i)$ экспериментальных результатов Y_i от рассчитанных по оценкам (1.72) значений функции регрессии $\tilde{Y}(x_i) = \tilde{B}_1 + \tilde{B}_2 x_i$:

$$\sum_{i=1}^n \Delta Y_i = 0, \quad (1.73)$$

Дисперсия адекватности (1.66) для проверки адекватности линейной регрессионной модели вычисляется по формуле

$$S_{\text{ад}}^2 = \frac{\sum_{i=1}^n (\Delta Y_i)^2}{k_{\text{ад}}} ; \quad k_{\text{ад}} = n - 2. \quad (1.74)$$

Границы доверительных интервалов для параметров линейной функции регрессии с кодированным переменным (1.71) имеют вид

$$\tilde{B}_1 \pm \varepsilon_1; \quad \varepsilon_1 = t_{1-\frac{\alpha}{2}}(k) \frac{S}{\sqrt{n}}; \quad \tilde{B}_2 \pm \varepsilon_2; \quad \varepsilon_2 = t_{1-\frac{\alpha}{2}}(k) \frac{S}{\sqrt{\sum_{i=1}^n X_i^2}}. \quad (1.75)$$

Оценки коэффициентов регрессии линейной функции (1.69) с реальным переменным при этом могут быть найдены по формулам:

$$\tilde{\beta}_1 = \tilde{B}_1 - \tilde{B}_2 \frac{\bar{x}}{h}; \quad \tilde{\beta}_2 = \frac{\tilde{B}_2}{h}. \quad (1.76)$$

Границы доверительных интервалов для коэффициентов линейной функции с реальным переменным (1.69) имеют вид

$$\begin{aligned} \tilde{\beta}_1 \pm \hat{\varepsilon}_1; & \quad \hat{\varepsilon}_1 = t_{1-\frac{\alpha}{2}}(k) S \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{h^2 \sum_{i=1}^n X_i^2}}; \\ \tilde{\beta}_2 \pm \hat{\varepsilon}_2; & \quad \hat{\varepsilon}_2 = t_{1-\frac{\alpha}{2}}(k) \frac{S}{h \sqrt{\sum_{i=1}^n X_i^2}}. \end{aligned} \quad (1.77)$$

2. Задача регрессии для квадратичной функции.

Рассмотрим случай, когда уравнение регрессии (1.61) является квадратичной функцией

$$y = \beta_1 + \beta_2 x + \beta_3 x^2, \quad (1.78)$$

т.е. базисные функции $\varphi_1(x) = 1$, $\varphi_2(x) = x$, $\varphi_3(x) = x^2$. В этом случае система (1.63) имеет

вид

$$\begin{cases} \beta_1 n + \beta_2 \sum_{i=1}^n x_i + \beta_3 \sum_{i=1}^n x_i^2 = \sum_{i=1}^n Y_i \\ \beta_1 \sum_{i=1}^n x_i + \beta_2 \sum_{i=1}^n x_i^2 + \beta_3 \sum_{i=1}^n x_i^3 = \sum_{i=1}^n Y_i x_i \\ \beta_1 \sum_{i=1}^n x_i^2 + \beta_2 \sum_{i=1}^n x_i^3 + \beta_3 \sum_{i=1}^n x_i^4 = \sum_{i=1}^n Y_i x_i^2 \end{cases} \quad (1.79)$$

Как и в предыдущем параграфе, сделаем замену $X = \frac{x - \bar{x}}{h}$, где $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ - среднее арифметическое аргументов x , h выбираем из условия, чтобы значения X были целыми, не имеющими общего множителя. Т.е. преобразуем уравнение (1.78) к виду

$$y = B_1 + B_2 X + B_3 X^2 = B_1 + B_2 \frac{x - \bar{x}}{h} + B_3 \left(\frac{x - \bar{x}}{h} \right)^2. \quad (1.80)$$

В этом случае $\sum_{i=1}^n X_i = 0$. Кроме того, введем условие $\sum_{i=1}^n X_i^3 = 0$. Оно будет выполняться, например, в том случае, когда переменная x в исходных данных меняется с постоянным шагом. Тогда система (1.79) существенно упрощается:

$$\begin{cases} B_1 n + B_3 \sum_{i=1}^n x_i^2 = \sum_{i=1}^n Y_i \\ B_2 \sum_{i=1}^n x_i^2 = \sum_{i=1}^n Y_i x_i \\ B_1 \sum_{i=1}^n x_i^2 + B_3 \sum_{i=1}^n x_i^4 = \sum_{i=1}^n Y_i x_i^2 \end{cases} \quad (1.81)$$

Решая эту систему, получаем формулы для оценок коэффициентов регрессии уравнения с кодированным переменным (1.80):

$$\tilde{B}_1 = \frac{\sum_{i=1}^n X_i^4 \cdot \sum_{i=1}^n Y_i - \sum_{i=1}^n X_i^2 \cdot \sum_{i=1}^n Y_i X_i^2}{n \sum_{i=1}^n X_i^4 - \left(\sum_{i=1}^n X_i^2 \right)^2}; \quad \tilde{B}_2 = \frac{\sum_{i=1}^n Y_i X_i}{\sum_{i=1}^n X_i^2}; \quad \tilde{B}_3 = \frac{n \sum_{i=1}^n Y_i X_i^2 - \sum_{i=1}^n X_i^2 \cdot \sum_{i=1}^n Y_i}{n \sum_{i=1}^n X_i^4 - \left(\sum_{i=1}^n X_i^2 \right)^2}. \quad (1.82)$$

Формула (1.73): $\sum_{i=1}^n \Delta Y_i = 0$ для квадратичной модели регрессии также имеет место, и ее удобно использовать для контроля расчетов. Дисперсия адекватности (1.66) для проверки адекватности квадратичной функции регрессии вычисляется по формуле

$$S_{\text{ад}}^2 = \frac{\sum_{i=1}^n (\Delta Y_i)^2}{k_{\text{ад}}}; \quad k_{\text{ад}} = n - 3. \quad (1.83)$$

Границы доверительных интервалов для параметров квадратичной функции регрессии с кодированным переменным (1.80) имеют вид

$$\begin{aligned} \tilde{B}_1 \pm \varepsilon_1; \quad \varepsilon_1 &= t_{\frac{1-\alpha}{2}}(k) S \sqrt{\frac{\sum_{i=1}^n X_i^4}{n \sum_{i=1}^n X_i^4 - \left(\sum_{i=1}^n X_i^2\right)^2}}; \\ \tilde{B}_2 \pm \varepsilon_2; \quad \varepsilon_2 &= t_{\frac{1-\alpha}{2}}(k) \frac{S}{\sqrt{\sum_{i=1}^n X_i^2}}. \\ \tilde{B}_3 \pm \varepsilon_3; \quad \varepsilon_3 &= t_{\frac{1-\alpha}{2}}(k) S \sqrt{\frac{n}{n \sum_{i=1}^n X_i^4 - \left(\sum_{i=1}^n X_i^2\right)^2}}. \end{aligned} \quad (1.84)$$

Оценки коэффициентов регрессии квадратичной функции с реальным переменным (1.78) при этом будут

$$\tilde{\beta}_1 = \tilde{B}_1 - \tilde{B}_2 \frac{\bar{x}}{h} + \tilde{B}_3 \left(\frac{\bar{x}}{h} \right)^2; \quad \tilde{\beta}_2 = \frac{\tilde{B}_2}{h} - \frac{2\tilde{B}_3 \bar{x}}{h^2}; \quad \tilde{\beta}_3 = \frac{\tilde{B}_3}{h^2}. \quad (1.85)$$

Границы доверительных интервалов для параметров квадратичной функции с реальным переменным (1.78) имеют вид

$$\begin{aligned} \tilde{\beta}_1 \pm \hat{\varepsilon}_1; \quad \hat{\varepsilon}_1 &= t_{\frac{1-\alpha}{2}}(k) S \sqrt{\frac{\sum_{i=1}^n X_i^4 + \frac{\bar{x}^4}{h^4} n}{n \sum_{i=1}^n X_i^4 - \left(\sum_{i=1}^n X_i^2\right)^2 + \frac{\bar{x}^2}{h^2 \sum_{i=1}^n X_i^2}}}; \\ \tilde{\beta}_2 \pm \hat{\varepsilon}_2; \quad \hat{\varepsilon}_2 &= t_{\frac{1-\alpha}{2}}(k) \frac{S}{h} \sqrt{\frac{1}{\sum_{i=1}^n X_i^2} + \frac{4n\bar{x}^2}{h^2 \left(n \sum_{i=1}^n X_i^4 - \left(\sum_{i=1}^n X_i^2\right)^2\right)}}, \\ \tilde{\beta}_3 \pm \hat{\varepsilon}_3; \quad \hat{\varepsilon}_3 &= t_{\frac{1-\alpha}{2}}(k) \frac{S}{h^2} \sqrt{\frac{n}{n \sum_{i=1}^n X_i^4 - \left(\sum_{i=1}^n X_i^2\right)^2}} \end{aligned} \quad (1.86)$$

Задача 1.25 Результаты экспериментов представлены в первых двух столбцах табл. 1.11. Экспериментальные значения Y являются независимыми и равноточными. Построить линейную и квадратичную регрессионные модели.

Условие задачи 1.25 и результаты расчета

x	Y	$X = \frac{x - 0,6}{0,2}$	$X \cdot Y$	X^2	$\bar{Y}_{\text{лин}}$	$\Delta Y_{\text{лин}}$	$\Delta Y_{\text{лин}}^2$
0,2	4,5	-2	-9,0	4	5,3	-0,8	0,64
0,4	7,0	-1	-7,0	1	6,25	0,75	0,56
0,6	8,0	0	0,0	0	7,2	0,8	0,64
0,8	7,5	1	7,5	1	8,15	-0,65	0,42
1,0	9,0	2	18,0	4	9,1	-0,1	0,04
Σ	3,0	36,0	0	9,5	10		2,30

Решение:

Сначала найдем решение задачи регрессии в кодированных значениях переменной x (1.71). Введем новую переменную по формуле $X = \frac{x - \bar{x}}{h}$, где $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{1}{5} \cdot 3 = 0,6$.

Если значения величины $x - 0,6$ поделить на число $h = 0,2$, то получатся целые значения, не имеющие общего множителя. Поэтому $X = \frac{x - 0,6}{0,2}$.

По формулам (1.72) находим оценки коэффициентов линейной регрессии

$$\tilde{B}_1 = \frac{\sum_{i=1}^n Y_i}{n} = \frac{36}{5} = 7,2; \quad \tilde{B}_2 = \frac{\sum_{i=1}^n Y_i X_i}{\sum_{i=1}^n X_i^2} = \frac{9,5}{10} = 0,95.$$

Получили линейную модель регрессии

$$\hat{Y}_{\text{лин}} = 7,2 + 0,95X.$$

По полученной формуле вычисляем значения линейной функции регрессии $\hat{Y}_{\text{лин}}$ при всех значениях аргумента X , а затем рассчитываем $\Delta Y_i = \hat{Y}_i - \hat{Y}_{i,\text{лин}}$ отклонения экспериментальных значений Y_i от значений $\hat{Y}_{i,\text{лин}}$, полученных по функции регрессии.

Контроль, согласно формуле $\sum_{i=1}^n \Delta Y_i = 0$, выполнен. Все расчеты приведены в таблице 1.11.

Уравнение линейной регрессии Y от реального переменного x найдем, сделав преобразование:

$$Y_{\text{лин}} = \beta_1 + \beta_2 x = 7,2 + 0,95 \frac{x - 0,6}{0,2} = 4,35 + 4,75x.$$

Построим квадратичную модель регрессии (1.80)

$$y = B_1 + B_2 X + B_3 X^2 = B_1 + B_2 \frac{x-0,6}{0,2} + B_3 \left(\frac{x-0,6}{0,2} \right)^2.$$

Заметим, что в нашем случае $\sum_{i=1}^n X_i^3 = 0$, поэтому для оценок коэффициентов регрессии можно воспользоваться формулами (1.82). Все расчеты приведены в таблице 1.12.

Таблица 1.12.

Результаты расчета квадратичной модели регрессии (к задаче 1.25)

	X^3	YX^2	X^4	$Y_{\text{кв}}$	$\Delta Y_{\text{кв}}$	$\Delta Y_{\text{кв}}^2$
	-8	18	16	4,8	-0,3	0,09
	-1	7	1	6,5	0,5	0,25
	0	0	0	7,7	0,3	0,09
	1	7,5	1	8,4	-0,9	0,81
	8	36	16	8,6	0,4	0,16
Σ	0	68,5	34		0	1,4

$$\tilde{B}_1 = \frac{\sum_{i=1}^n X_i^4 \cdot \sum_{i=1}^n Y_i - \sum_{i=1}^n X_i^2 \cdot \sum_{i=1}^n Y_i X_i^2}{n \sum_{i=1}^n X_i^4 - \left(\sum_{i=1}^n X_i^2 \right)^2} = \frac{34 \cdot 36 - 10 \cdot 68,5}{5 \cdot 34 - 100} = 7,7;$$

$$\tilde{B}_2 = \frac{\sum_{i=1}^n Y_i X_i}{\sum_{i=1}^n X_i^2} = \frac{9,5}{10} = 0,95;$$

$$\tilde{B}_3 = \frac{n \sum_{i=1}^n Y_i X_i^2 - \sum_{i=1}^n X_i^2 \cdot \sum_{i=1}^n Y_i}{n \sum_{i=1}^n X_i^4 - \left(\sum_{i=1}^n X_i^2 \right)^2} = \frac{5 \cdot 68,5 - 10 \cdot 36}{5 \cdot 34 - 100} = -0,25.$$

Получили квадратичную модель регрессии

$$\hat{Y}_{\text{кв}} = 7,7 + 0,95X - 0,25X^2.$$

Условие $\sum_{i=1}^n \Delta Y_i = 0$, выполняется.

Уравнение квадратичной регрессии Y от реального переменного x найдем, сделав преобразование:

$$Y_{\kappa 6} = \beta_1 + \beta_2 x + \beta_3 x^2 = 7,7 + 0,95 \frac{x - 0,6}{0,2} - 0,25 \left(\frac{x - 0,6}{0,2} \right)^2 = 2,6 + 12,25x - 6,25x^2.$$

Пригодность каждой из полученных регрессионных моделей будет оценена на следующем занятии.