


Метод наименьших квадратов

Метод наименьших квадратов с успехом применяется при необходимости приближенного представления опытных данных или полученного в виде таблицы решения некоторой задачи аналитической функцией, то есть в виде формулы, с которой удобнее работать при последующих вычислениях или анализе результатов. Этот процесс часто называют аппроксимацией опытных данных (решения задачи).

Пусть связь между переменными x и y представлена таблицей, содержащей n точек (x_k, y_k) :

x	x_1	x_2	x_3	x_4	x_5	x_n
y	y_1	y_2	y_3	y_4	y_5	y_n

Вначале выберем, вообще говоря, произвольно аппроксимирующую функцию, например, $y = ax + b$. Такая аппроксимация называется линейной. Остается определить a, b , но для этого достаточно двух точек, так как через две точки проходит единственная прямая. В нашем примере точек значительно больше, причем совсем необязательно они лежат на найденной прямой. Очевидно, параметрами a, b следует распорядиться так, чтобы точки, заданные таблицей, лежали как можно ближе к этой прямой, то есть суммарная погрешность аппроксимации была минимальной. Поскольку заданные точки могут лежать как выше, так и ниже аппроксимирующей прямой, то есть расстояния между табличными точками и точками прямой могут быть и положительными, и отрицательными.



То есть величина каждой погрешности может быть достаточно большой, а суммарная погрешность окажется малой в результате суммирования положительных и отрицательных величин. Это может создать ложное представление о качестве аппроксимирующей функции. Чтобы ликвидировать этот недостаток, было решено суммировать квадраты погрешностей, то есть положительные величины, а параметры a, b подбирать так, чтобы суммарная погрешность аппроксимации была минимальной.

Введем функцию "невязки", то есть суммарной погрешности

$$F(a, b) = \sum_{k=1}^n [y_k - (ax_k + b)]^2 = \sum_{k=1}^n (y_k - ax_k - b)^2,$$

здесь (x_k, y_k) - табличные точки, $ax_k + b$ - точки лежащие на аппроксимирующей прямой и соответствующие тому же значению x_k .

Остается определить минимум этой функции двух переменных. Очевидно, точки экстремума функции определяются из системы уравнений

$$\frac{\partial F(a, b)}{\partial a} = 0, \quad \frac{\partial F(a, b)}{\partial b} = 0.$$

Поскольку

$$\frac{\partial F(a, b)}{\partial a} = \sum_{k=1}^n 2(y_k - ax_k - b)(-x_k), \quad \frac{\partial F(a, b)}{\partial b} = \sum_{k=1}^n 2(y_k - ax_k - b)(-1),$$

имеем

$$\begin{cases} a \sum_{k=1}^n x_k^2 + b \sum_{k=1}^n x_k = \sum_{k=1}^n x_k y_k \\ a \sum_{k=1}^n x_k + b \sum_{k=1}^n 1 = \sum_{k=1}^n y_k \end{cases}$$

или

$$\begin{cases} a \sum_{k=1}^n x_k^2 + b \sum_{k=1}^n x_k = \sum_{k=1}^n x_k y_k \\ a \sum_{k=1}^n x_k + n b = \sum_{k=1}^n y_k \end{cases}.$$

Остается показать, что найденные из этой системы a, b соответствуют минимуму функции, для этого определим

$$\frac{\partial^2 F(a, b)}{\partial a^2} = 2 \sum_{k=1}^n x_k^2, \quad \frac{\partial^2 F(a, b)}{\partial b^2} = 2 \sum_{k=1}^n 1 = 2n, \quad \frac{\partial^2 F(a, b)}{\partial a \partial b} = 2 \sum_{k=1}^n x_k.$$

Тогда

$$\nabla = \frac{\partial^2 F(a, b)}{\partial a^2} \frac{\partial^2 F(a, b)}{\partial b^2} - \left(\frac{\partial^2 F(a, b)}{\partial a \partial b} \right)^2 = 4 \left[n \sum_{k=1}^n x_k^2 - \left(\sum_{k=1}^n x_k \right)^2 \right].$$

Из неравенства Коши $\left(\sum_{k=1}^n x_k z_k \right)^2 \leq \sum_{k=1}^n x_k^2 \sum_{k=1}^n z_k^2$ при $z_k = 1$ получаем

$$\left(\sum_{k=1}^n x_k \right)^2 < n \sum_{k=1}^n x_k^2 \quad (\text{равенство в этом случае возможно только при всех } x_k = 1),$$

откуда следует $\nabla > 0$, но условия $\nabla > 0$, $\frac{\partial^2 F(a, b)}{\partial a^2} = 2 \sum_{k=1}^n x_k^2 > 0$ являются условиями минимума функции "невязки" $F(a, b)$, о чем говорилось выше.

Можно в качестве аппроксимирующих функций выбирать другие функции. Например, $y = ax^2 + bx + c$, которая зависит от трех параметров a, b, c , определяемых из тех же соображений. Функция суммарной погрешности в этом случае имеет вид

$$\Phi(a, b, c) = \sum_{k=1}^n \left[y_k - (ax_k^2 + bx_k + c) \right]^2 = \sum_{k=1}^n (y_k - ax_k^2 - bx_k - c)^2.$$

Из

$$\begin{aligned} \frac{\partial \Phi(a, b, c)}{\partial a} &= \sum_{k=1}^n 2(y_k - ax_k^2 - bx_k - c)(-x_k^2) \\ \frac{\partial \Phi(a, b, c)}{\partial b} &= \sum_{k=1}^n 2(y_k - ax_k^2 - bx_k - c)(-x_k) \\ \frac{\partial \Phi(a, b, c)}{\partial c} &= \sum_{k=1}^n 2(y_k - ax_k^2 - bx_k - c)(-1) \end{aligned}$$

получаем систему уравнений относительно a, b, c :

$$\begin{cases} a \sum_{k=1}^n x_k^4 + b \sum_{k=1}^n x_k^3 + c \sum_{k=1}^n x_k^2 = \sum_{k=1}^n x_k^2 y_k \\ a \sum_{k=1}^n x_k^3 + b \sum_{k=1}^n x_k^2 + c \sum_{k=1}^n x_k = \sum_{k=1}^n x_k y_k \\ a \sum_{k=1}^n x_k^2 + b \sum_{k=1}^n x_k + nc = \sum_{k=1}^n y_k \end{cases}$$

Доказано, что при этом достигается минимальная погрешность аппроксимации.

Пример

X	1.0	1.5	2.0	2.5	3.0	3.5	4.0	4.5	5.0
Y	8.0	8.5	9.0	9.0	8.0	7.0	5.0	3.0	0

а). Пусть $y = ax + b$, тогда относительно параметров прямой имеем систему уравнений

$$\begin{cases} a \sum_{k=1}^9 x_k^2 + b \sum_{k=1}^9 x_k = \sum_{k=1}^9 x_k y_k \\ a \sum_{k=1}^9 x_k + 9b = \sum_{k=1}^9 y_k \end{cases}.$$

Подсчитаем

$$\sum_{k=1}^9 x_k = 1.0 + 1.5 + 2.0 + 2.5 + 3.0 + 3.5 + 4.0 + 4.5 + 5.0 = 27,$$

$$\sum_{k=1}^9 y_k = 8.0 + 8.5 + 9.0 + 9.0 + 8.0 + 7.0 + 5.0 + 3.0 + 0 = 57.5,$$

$$\sum_{k=1}^9 x_k^2 = 1.0 + 2.25 + 4.0 + 6.25 + 9.0 + 12.25 + 16.0 + 20.25 + 25 = 96,$$


$$\sum_{k=1}^9 x_k y_k = 8.0 + 12.75 + 18.0 + 22.5 + 24.0 + 24.5 + 20.0 + 13.5 + 0 = 143.25.$$

В итоге имеем систему

$$\begin{cases} 96a + 27b = 143.25 \\ 27a + 9b = 57.5 \end{cases}$$

Тогда $a = -1.95$, $b = 12.24$, и аппроксимирующая функция $y = -1.95x + 12.24$.

Приведем график, показывающий погрешность линейной аппроксимации данных таблицы



б). Пусть $y = ax^2 + bx + c$, тогда относительно параметров прямой имеем систему уравнений

$$\begin{cases} a \sum_{k=1}^n x_k^4 + b \sum_{k=1}^n x_k^3 + c \sum_{k=1}^n x_k^2 = \sum_{k=1}^n x_k^2 y_k \\ a \sum_{k=1}^n x_k^3 + b \sum_{k=1}^n x_k^2 + c \sum_{k=1}^n x_k = \sum_{k=1}^n x_k y_k \\ a \sum_{k=1}^n x_k^2 + b \sum_{k=1}^n x_k + nc = \sum_{k=1}^n y_k \end{cases}$$

Некоторые коэффициенты этой системы уравнений определены выше, подсчитаем остальные


$$\sum_{k=1}^9 x_k^3 = 378 \quad \sum_{k=1}^9 x_k^4 = 1583.25, \quad \sum_{k=1}^9 x_k^2 y_k = 417.875$$

Теперь

$$\begin{cases} 1583.25 a + 378 b + 96 c = 417.875 \\ 378 a + 96 b + 27 c = 143.25 \\ 96 a + 27 b + 9 c = 57.5 \end{cases}$$

откуда следует $a = -1.037$, $b = 4.27$, $c = 4.64$ и $y = -1.037 x^2 + 4.27 x + 4.64$.

На графике показана погрешность аппроксимации табличных данных кривой второго порядка



Сравнивая графики, нетрудно заметить, что в данном случае линейная аппроксимация приводит к значительному отклонению табличных данных от прямой $y = -1.95x + 12.24$. В то же время эти точки практически ложатся на параболу $y = -1.037 x^2 + 4.27 x + 4.64$.